

Agent-Meow 语音管线全链路审计报告

Voice Pipeline Sequence & Timing Audit — Client Review Edition

日期: 2026-09-03 · 分支: feat/040-unified-workspace @ 8579bbd2a · 环境: 全部服务在线实测 服务: agent-meow :6767 · Hermes 网关 :8642 · whisper.cpp Vulkan :8001 · Qwen3-TTS Vulkan :8891 · Ollama :11434

1. 执行摘要 (Executive Summary)

评估项	结论
全链路时延 (热态, STT→LLM→TTS)	≈ 2.0 – 3.3 s ✅ 达标
STT 中文准确率 (真实语音)	8/8 内容字全对 (直连逐字精确; 经代理多出敬语替换“你→您”) ✅
TTS 反幻觉 / 反废音防护	8 层防线 (客户端 7 + 服务端 1) ✅
全链路无挂起保障	每一段均有超时/兜底, 单点无死锁 ✅
噪声 / 回声 / 重叠 / 双输入防护	4 层防护 + 唯一修复 (本次提交 8579bbd2a) ✅

本次新增修复 (8579bbd2a, 已推送):

- Stop 后循环卡死** — `turnCancelled` 中途重置导致每次打断后所有后续回合被静默吞掉; 已改为回合入口重置。
- SSE 流挂死** — 主 LLM 路由无读取超时; 半开连接会把 `voiceState` 永久卡在 "processing"; 已加 90 秒停滞截止。

2. 全链路时序图 (Sequence Map)

2.1 单回合主流程 (听→处理→说)

```
sequenceDiagram
    participant M as 麦克风
    participant V as Silero VAD (v5)
    participant S as STT (whisper.cpp Vulkan)
    participant L as LLM (Hermes→Ollama)
    participant T as TTS (Edge 主 → Qwen 备)
    participant Spk as 扬声器

    M->>V: 语音段采集 (16kHz)
    V->>V: 静音 1000ms 判定句末 (redemptionMs)
    V->>S: 音频段 → WAV → POST /v1/audio/transcriptions
    Note over V: 此刻 VAD 暂停 (ASR-OFF) <br/> pauseVadForTurn()
    S->>L: 文本 → 意图分类 → 会话 SSE 流
    L-->>T: text_delta 逐句 (句号/子句切分)
    T->>Spk: 3 路并行合成 + 严格顺序播放
    Note over Spk: playback.started → speaking
    T->>V: 播放结束 + 500ms 回声尾延迟 <br/> resumeVadAfterTurn()
    Spk-->>M: 回到监听 (audio.done → listening)
```

2.2 各阶段实测时延（2026-09-03 实测，N=3）

阶段	冷启动	热态（均值）	目标	判定
VAD 句末判定	—	+1.0 s（redemptionMs=1000，含在"说话等待"内）	—	设计值
STT（经 :6767 代理）	~1.5 s	0.67 – 0.94 s	<1.5 s	✓
STT（直连 :8001）	1.5 s	0.26 s	—	代理开销 ≈0.4–0.7 s
意图分类	—	<0.3 s（本地规则）	—	—
LLM（Hermes 小回复）	—	1.0 – 1.3 s	<3 s	✓
TTS Edge（首句）	—	0.77 – 1.40 s	<2 s	✓
TTS Qwen 直连（备用）	—	0.29 – 0.36 s	<1 s	✓
首音频延迟（首句合成）	—	≈ 2.5 – 3.5 s	<5 s	✓
完整回合（说→听）	—	2.0 – 3.3 s	<5 s	✓

8 月 26 日历史基线（冷态/异常态）为参考：完整管线 4–8 s；乱码事故 50 s（已被 mojiwake 检测杜绝）。

3. STT 中文准确率

3.1 实测（真实语音，输入「你好，今天天气怎么样」）

路径	转写结果	判定
直连 whisper.cpp :8001	你好,今天天气怎么样?	8/8 字精确 ✓
经 :6767 代理	您好,今天天气怎么样?	内容 8/8 ✓ ("你→您"为代理层敬语替换，语义相同)

- 模型：ggml-large-v3-turbo（Vulkan iGPU，`--language zh --prompt "橘宝agent-meow语音工作目录会话"`）
- 语言提示自适应：默认 zh；检测到 CJK → 锁定 zh；连续 2 条非 CJK → 切 en；连续 3 次 en 卡死 → 探测 auto；空转写保留 zh（VAD 碎片防翻转）。
- 历史缺陷已修：whisper-server 端点默认语言覆盖 CLI 参数 → 已强制表单 `language=zh`；合成音 PCM 默认无头（audio/pcm）→ whisper 拒收，需 `response_format:'wav'`。

3.2 已知精度边界

场景	表现
短音频 (1s) 空文本	正确返回空（不幻觉） ✓

专有名词「橘宝」	faster-whisper 缺上下文 → 靠 8 个同音词表兜底（去吧/据报/拘保 等，实测出现过「去吧」）
正弦波 440Hz 合成音	正确返回空；曾触发蒙古文幻觉「ө」→ 已被过滤

4. 噪声 / 空隙 / 泄漏 / 重叠 防护矩阵

#	防线	触发点	参数	防什么
N1	VAD 门槛	posTh 0.6 / negTh 0.45 / minSpeechMs 300	VAD 段前	噪声瞬态、极短杂音
N2	回合暂停	pauseVadForTurn()（每回合入口）	STT→LLM→TTS 空隙	空档期旁白被吸入下一回合（间隙泄漏）
N3	播放静默	onSpeechEnd 三重门槛 ttsPlaying isProcessing vadPaused	TTS 播放中	自己说话声被当作用户输入（回声/重叠）
N4	恢复延迟	RESUME_ECHO_TAIL_MS = 500	回合结束	扬声器物理衰减尾巴被转写成幻影用户回合
N5	回声比对	isLikelyReplyEcho（≤12 字且与上条回复共享 ≥4 字片段）	STT 后	转写结果=上条回复的引用碎片
N6	重复回合	isDuplicateSttTurn（全等；≤12 字且为子串）	STT 后	VAD 拆句 / 用户抢话重复
N7	唯一互斥	ComposerMicButton 拒绝在 VAD 会话中开启听写	麦克风获取	双输入（两个 getUserMedia 并存）
N8	幽灵提交	!turnCancelled 门控 voice.command 自动提交	任务意图路径	被打断的回合复活提交

间隙 (gap) 清单：句末静音 1.0 s（VAD 判定）→ STT ~0.9 s → 首句 LLM ~0.3–1 s → TTS ~1 s；全链路对用户表现为“说完 ~2.5–3.5 s 后开口回复”。恢复侧 500 ms 尾延迟 + 300 ms ttsPlaying 排空计时器为固定成本，不随长度增长。

5. TTS 反幻觉 / 反废音 8 层防线

#	防线	位置	规则
T1	Whisper 幻觉过滤	filterWhisperHallucination	26 个模式 6 类：zh 元数据（简体中文/简体字/规范汉字）、zh 订阅/YouTube CTA×10、英文 CTA×3、哈萨克 қыл 系、蒙古 ө、嗯嗯 系 + 重复 token 检测（2–6 字 token 连续 3+ 次全等 → 丢弃）
T2	乱码检测	isMojibake	U+FFFD / 罕用 CJK 密度 >40% / GBK 签名（罕见字+半角标点）→ 直接跳过 TTS（杜绝 48 s 音频事故）
T3	净化管道	sanitizeForTts	emoji/Markdown/URL/零宽/括号/引号全剥；喵喵喵、哈哈、呵呵、嘻嘻、嗯嗯、啊啊、呜呜等副语言全剥（实测各

			+1.4 s 怪声)；标点映射 (；: ...→。; ? 与，原生保留—— 2026-08-29 已验证 Vulkan 引擎正确处理问句语调)
T4	文本上限	MAX_TTS_TEXT_LEN = 200	超长文本跳过 TTS
T5	音频字节上限	MAX_TTS_AUDIO_BYTES = 2MB	Edge 与 Qwen 结果均校验
T6	音频时长合理性	synthesize()	预期 = max(96KB, N/3 字×96KB)； 超 5 倍即拒收 （杜绝 2 字 21 s 音频）
T7	服务端字节封顶	voice_proxy.py:899	max(100KB, min(15KB/字, 2MB))，原生 TTS 流中途截断
T8	引擎降级序	客户端 synthesize()	Edge（1 次重试）→ Qwen → 两败则 跳句 并报 tts.skipped（永不挂起、无静默洞——超时 30 s 兜底）

引擎顺序（用户确认的架构）：Edge TTS（晓晓，云）为主 → Qwen3-TTS（Serena，Vulkan 本地）为备；每回合锁定引擎避免中途换声。服务端另有 Hermes 5xx/连接失败 → :8891 的自动降级。

6. 无挂起保障（"任何环节不得卡死"）

环节	超时/兜底	挂死后果已消除?
STT 请求	TURN_FETCH_TIMEOUT_MS = 30s；连接前 2 s 健康探测（whisper 不可达 → Hermes STT 降级）	✓
LLM（Hermes 路径）	30 s 硬截止（AbortSignal.any，中断仍可用）	✓
LLM（主路径：会话 SSE）	90 s 停滞截止 （新修复）；心跳 15 s/次证明链路活；中断信号随时可切	✓（本次修复）
TTS 单句	30 s fetch 超时 + 双引擎降级 + 跳句	✓
VAD 恢复	finally 单一恢复者 + 500 ms 尾延迟	✓
Stop/打断	中止 SSE、停声、清队、恢复 VAD、状态回 listening；turnCancelled 入口重置（新修复）	✓（本次修复）
断开清理	VAD 销毁、AudioContext 关闭、全部标志清零（含 turnCancelled）	✓
服务进程	service_supervisor 看护：5s/10s/30s 退避，最多 3 次后 degraded	✓（进程级）

7. 状态机 (Listening → Processing → Speaking → Listening)

```
stateDiagram-v2
    [*] --> disconnected
    disconnected --> listening: 连接成功 (VAD 启动)
    listening --> processing: 语音段进入回合 (turn.started)
    processing --> speaking: 首句音频 playback.started
    speaking --> listening: 播放完 + 500ms 尾延迟 (audio.done)
```

processing --> listening: 提前返回/错误 (error → H2 重置)
speaking --> listening: Stop (playback.clear, 规则13)
listening --> disconnected: 用户断开
note right of processing: ASR-OFF: VAD 暂停
无 barge-in (v1)

- 单一权威信号 `getVoiceState()` : `ttsPlaying→speaking` ; `isProcessing→processing` ; `connected&&!vadPaused→listening` ; 其余 `disconnected` 。
- 唤醒门: 橘宝 (14 个唤醒词表) → 门开一回合 → 回合毕自动复门; 唤醒回合绝无 LLM 泄漏。

8. 风险登记表（已接受 / 待办）

#	风险	等级	状态
R1	爪键可在听写进行时开启第二麦克风（状态源为 VAD 而非听写）	低	记录待修（UI 传参）
R2	双 TTS 全败时静音（beep 占位函数未接线，仅报 <code>tts.skipped</code> ）	低	记录待接线
R3	STT 无浏览器内降级（服务端探测式降级 + 无熔断；卡死 whisper 每请求耗 2 s 探测）	中	记录待加强
R4	<code>voice_proxy.py</code> 模块头注释仍写“Qwen 为主”（与代码/路由描述相悖）	文档	待改
R5	服务重启端点 bug: <code>restart/whisper_server</code> 实际重启 TTS	低	待修
R6	唤醒词「橘宝，帮我...」前缀未从 LLM 输入剥离	极低	记录
R7	<code>test_voice_proxy.py</code> 3 个预置失败（注册表竞态断言，2026-08-26 已记录）	已知	不阻塞

9. 验证与可复现

- 测试门: tsc 干净; 语音前端 **146/146** (`hermesVoice` 72 + `useRealtimeVoice` 27 + `ComposerMicButton` 30 + `VoicePawButton` 17); chips 套件 **78/78**; 听写后端 **32/32**; `file-index` 后端 **46/46**; `voice_proxy` **12/15** (3 个预置失败)。
- 实测命令模板 (UTF-8 JSON 须写文件后 `--data-binary @file` , `curl` 内联 CJK 会坏):

```
curl -s -X POST http://127.0.0.1:6767/v1/audio/transcriptions -F "file=@bench.wav" -F "language=zh"
curl -s -X POST http://127.0.0.1:6767/v1/audio/speech/edge --data-binary @edge.json -H "Content-Type: application/json"
curl -s -X POST http://127.0.0.1:8891/v1/audio/speech --data-binary @qwen.json -H "Content-Type: application/json"
```

- 修复提交: 8579bbd2a (turnCancelled 入口重置 + disconnect 清零 + SSE 90s 停滞截止); 基线审计链见 426bb4b2c 、 104fb9bc4 。

报告由全代码级审计 (`hermesVoice.ts` / `useRealtimeVoice.ts` / `voice_proxy.py` / `service_supervisor.py` / `voiceIntent.ts` / `wakeWords.ts`) + 当日实时基准生成。所有行号对应 8579bbd2a 快照。