

# 计划 008 概要

---

GPU 加速语音识别（离线预热优化）

## 问题

本地 S2S 语音服务器预热需要 **90 秒**。

根因：faster-whisper 只支持 CUDA，无法使用本机的 AMD GPU——**GPU 和 NPU 完全闲置**。

## 目标

用 whisper.cpp + Vulkan 将语音识别放到 GPU 上运行。

预热时间从 **90 秒** → **~8 秒**

(配合预热机制可至 **~0 秒**)

## 机器配置

- **CPU**: AMD Ryzen AI MAX+ 395 (16 核 / 32 线程, 32GB 内存)
- **GPU**: AMD Radeon 8060S 集成显卡 (Vulkan 1.4.329 )
- **NPU**: AMD XDNA 2 NPU (已识别 )
- **ROCm**: AMD ROCm 7.1 (已安装 )

# 范围

| 范围内                                            | 范围外                         |
|------------------------------------------------|-----------------------------|
| 克隆并构建 whisper.cpp (Vulkan)                     | 前端代码 ( web/ )               |
| scripts/start-whisper-server-vulkan.ps1 (新建)   | 后端代码 ( agent_meow/server/ ) |
| scripts/start-speech-to-speech.ps1 (修改 STT 来源) | S2S Python 包源码              |

## 步骤概要

1. **构建** — `cmake -DGGML_VULKAN=1` 编译 whisper.cpp
2. **测速** — GPU vs CPU 基准对比（目标：编码器 <5 秒）
3. **启动** — `whisper-server` 监听 `:8888`，模型加载到 GPU 显存
4. **脚本** — 创建开机启动脚本
5. **接入** — 将 S2S 的 STT 切换到 whisper-server
6. **预热 TTS** — 开机时发送虚拟请求预热 Kokoro
7. **冒烟测试** — 离线语音往返 <10 秒

# 架构图

开机后台启动（用户无感）

Hermes Docker (:8642) ← 已运行

whisper-server (:8888) ← GPU 加载 ~3 秒

S2S 服务器 (:8765) ← 使用 GPU STT + 预热 TTS

QAA 网关 (:3101)

用户操作

打开浏览器 → 点击猫爪麦克风 → 说话 → 即时响应

# 预期效果

| 指标      | 优化前          | 优化后                    |
|---------|--------------|------------------------|
| STT 预热  | ~60 秒（CPU）   | ~3 秒（GPU Vulkan）       |
| TTS 预热  | ~30 秒        | ~0 秒（开机预热）             |
| 总预热     | <b>~90 秒</b> | <b>~8 秒</b> （或 ~0 秒热池） |
| GPU 利用率 | 0%（闲置）       | STT 在 GPU 运行           |
| 成本      | 免费           | 免费（本地，无云端）             |