

计划 008 概要

GPU 加速语音识别（离线预热优化）

背景（已解决）

原本地 S2S 语音服务器预热需 **90 秒**，现已解决。

根因：faster-whisper 只支持 CUDA，无法使用本机的 AMD GPU——**GPU 和 NPU 完全闲置。**

已实现

用 whisper.cpp + Vulkan 将语音识别放到 GPU 上运行。

预热时间从 **90 秒** → **~8 秒**

(配合预热机制可至 **~0 秒**)

机器配置

- **CPU**: AMD Ryzen AI MAX+ 395 (16 核 / 32 线程, 3.0GHz, 128GB 内存)
- **GPU**: AMD Radeon 8060S 集成显卡 (Vulkan 1.4.329 )
- **NPU**: AMD XDNA 2 NPU (活跃辅助推理 )
- **ROCm**: AMD ROCm 7.1 (已安装 )

范围

范围内	范围外
克隆并构建 whisper.cpp (Vulkan)	前端代码 (web/)
scripts/start-whisper-server-vulkan.ps1 (新建)	后端代码 (agent_meow/server/)
scripts/start-speech-to-speech.ps1 (修改 STT 来源)	S2S Python 包源码

步骤概要

1. **构建** — `cmake -DGGML_VULKAN=1` 编译 whisper.cpp
2. **测速** — GPU vs CPU 基准对比（目标：编码器 <5 秒）
3. **启动** — `whisper-server` 监听 `:8888`，模型加载到 GPU 显存
4. **脚本** — 创建开机启动脚本
5. **接入** — 将 S2S 的 STT 切换到 whisper-server
6. **预热 TTS** — 开机时发送虚拟请求预热 Kokoro
7. **冒烟测试** — 离线语音往返 <10 秒

架构图

开机后台启动（用户无感）

Hermes Docker (:8642) ← 已运行

whisper-server (:8888) ← GPU 加载 ~3 秒

S2S 服务器 (:8765) ← 使用 GPU STT + 预热 TTS

QAA 网关 (:3101)

用户操作

打开浏览器 → 点击猫爪麦克风 → 说话 → 即时响应

预期效果

指标	优化前	已实现
STT 预热	~60 秒（CPU）	~3 秒（GPU Vulkan）
TTS 预热	~30 秒	~0 秒（开机预热）
总预热	~90 秒	~8 秒 （或 ~0 秒热池）
GPU 利用率	0%（闲置）	STT 在 GPU 运行
成本	免费	免费（本地，无云端）