

agent-meow 语音代理项目概览

灵创K16 + 橘宝R16 双平台方案

目标：在两台笔记本上实现零云端、零外部 GPU 的本地 AI 语音代理

日期：2026-08-04 • **状态：**灵创K16 方案已就绪，橘宝R16 评估中

项目目标：解决什么问题？

已解决：原语音代理冷启动 90 秒问题已解决，现已实现即时响应

实现效果：

指标	优化前	已实现
语音启动	90 秒	即时（在线） / ~8 秒（离线）
云端依赖	必须联网	可选（离线可用）
运行成本	API 持续计费	零（离线模式）
AI 能力	仅对话	对话 + 工具调用（代码/文件）

核心价值：语音即入口 — 用户说话即可与 AI 交互，AI 可调用工具完成任务

两台设备一览

	灵创K16	橘宝R16
定位	高端旗舰，大模型质量优先	性价比之选，CUDA 加速优先
处理器	AMD Ryzen AI MAX+ 395	AMD Ryzen AI 9 HX 470
显卡	内置 Radeon 8060S (96GB显存)	内置 Radeon 890M + RTX 5060 (8GB)
AI 芯片	NPU (XDNA 2, 活跃辅助)	NPU (XDNA 2, ~50 TOPS)
内存	128GB	32GB
优势	96GB 显存跑最大模型	RTX 5060 CUDA 原生加速

同一软件，两种硬件：agent-meow 在两台设备上提供相同功能，性能特征不同

方案概述：4 个阶段

阶段	内容	说明
1	云端语音 + GPU 语音识别	并行开发，互不依赖
2	用户界面集成 + 混合模式	依赖阶段 1
3	AI 工具调用能力	依赖阶段 1
4	本地大模型推理	依赖阶段 3

总工作量：5 个计划 (006-010)，预计 2-4 周

阶段 1：云端语音 + GPU 加速

计划 006：安装语音网关 + 阿里云 DashScope

- 已解决 90 秒冷启动 → **即时响应**（云端常驻）
- 中文语音质量优秀，中国可直连
- 90 天免费试用，之后 ~¥0.20/分钟

计划 008：GPU 语音识别加速

- 灵创K16：用 Vulkan 技术将语音识别放到 GPU（60s → ~3s）
- 橘宝R16：RTX 5060 原生支持 CUDA，**直接安装即可**（60s → ~1s）

结果：在线模式即时响应，离线模式 3-8 秒启动

阶段 2：用户界面 + 混合模式

计划 006b：在线/离线自动切换

- 云端不可用时自动切离线，用户无感知
- 解决中国网络环境下的可用性问题的

计划 007：保留猫爪 UI，替换底层引擎

- 用户看到的界面不变（猫爪按钮 + 波形动画）
- 内部传输层升级为更成熟的 QAA 协议
- 新增在线/离线切换按钮

结果：用户体验一致，底层更稳定

阶段 3+4：AI 工具调用 + 本地大模型

计划 009：AI 语音 → 工具调用

- 用户说话 → 简单问题即时回答
- 需要工具时（代码/文件/搜索）→ 后台执行 → 语音播报结果
- AI 语音成为工作入口，不仅仅是聊天

计划 010：本地大模型推理

- 灵创K16：35B 大模型完全驻留 96GB 显存（128GB 总内存，最高质量）
- 橘宝R16：同一 35B 模型，智能分配到 RTX 5060 + 系统内存
- **零 API 费用**，完全本地运行

结果：语音驱动的 AI 代理，可执行任务，零云端成本

两台设备最终效果对比

指标	灵创K16	橘宝R16
语音启动	即时（在线） / ~8s（离线）	即时（在线） / ~3s（离线）
语音识别	GPU ~3s (Vulkan)	GPU ~1s (CUDA)
AI 模型	35B 大模型（最高质量）	同 35B 模型（稍压缩）
离线运行	✅ 零云端	✅ 零云端
实现难度	中等（需编译）	简单（直接安装）

总结：灵创K16 以大显存追求最高质量；橘宝R16 以 CUDA 追求最快速度和最简部署

成本与风险

开发成本：

项目	灵创K16	橘宝R16
云端语音	90天免费，后 ~¥0.20/分	同
离线运行	零成本	零成本
开发工作量	中等	较低

风险：

风险	级别	缓解措施
云端服务不可用	低	自动切离线模式
GPU 兼容性	中	已验证两平台驱动
模型性能不足	低	可切换更小模型

项目愿景

agent-meow 是一个语音优先的 AI 代理，用户通过说话即可：

-  **对话**：自然语言交流，中英文双语
-  **执行任务**：调用代码、文件、搜索等工具
-  **完全本地**：离线可用，零云端费用
-  **品牌体验**：猫爪 UI，独特的交互设计

双平台覆盖：

- 灵创K16 面向高端用户（128GB 内存/96GB 显存，最大模型）
- 橘宝R16 面向主流用户（RTX 5060 CUDA，性价比高）

两个平台运行同一软件，提供同一体验，适配不同硬件。