

# agent-meow 语音代理项目概览

灵创K16 + 橘宝R16 双平台方案

**目标：**在两台笔记本上实现零云端、零外部 GPU 的本地 AI 语音代理

**日期：**2026-08-04 • **状态：**灵创K16 方案已就绪，橘宝R16 评估中

# 项目目标：解决什么问题？

**已解决：**原语音代理冷启动 90 秒问题已解决，现已实现即时响应

**实现效果：**

| 指标    | 优化前      | 已实现               |
|-------|----------|-------------------|
| 语音启动  | 90 秒     | 即时（在线） / ~8 秒（离线） |
| 云端依赖  | 必须联网     | 可选（离线可用）          |
| 运行成本  | API 持续计费 | 零（离线模式）           |
| AI 能力 | 仅对话      | 对话 + 工具调用（代码/文件）  |

**核心价值：**语音即入口 — 用户说话即可与 AI 交互，AI 可调用工具完成任务

# 两台设备一览

|       | 灵创K16                  | 橘宝R16                           |
|-------|------------------------|---------------------------------|
| 定位    | 高端旗舰，大模型质量优先           | 性价比之选，CUDA 加速优先                 |
| 处理器   | AMD Ryzen AI MAX+ 395  | AMD Ryzen AI 9 HX 470           |
| 显卡    | 内置 Radeon 8060S (96GB) | 内置 Radeon 890M + RTX 5060 (8GB) |
| AI 芯片 | NPU (XDNA 2)           | NPU (XDNA 2)                    |
| 内存    | 32GB                   | 32GB                            |
| 优势    | 96GB 显存跑最大模型           | RTX 5060 CUDA 原生加速              |

同一软件，两种硬件：agent-meow 在两台设备上提供相同功能，性能特征不同

# 方案概述：4 个阶段

| 阶段 | 内容              | 说明        |
|----|-----------------|-----------|
| 1  | 云端语音 + GPU 语音识别 | 并行开发，互不依赖 |
| 2  | 用户界面集成 + 混合模式   | 依赖阶段 1    |
| 3  | AI 工具调用能力       | 依赖阶段 1    |
| 4  | 本地大模型推理         | 依赖阶段 3    |

**总工作量：**5 个计划 (006-010)，预计 2-4 周

# 阶段 1：云端语音 + GPU 加速

---

## 计划 006：安装语音网关 + 阿里云 DashScope

- 已解决 90 秒冷启动 → **即时响应**（云端常驻）
- 中文语音质量优秀，中国可直连
- 90 天免费试用，之后 ~¥0.20/分钟

## 计划 008：GPU 语音识别加速

- 灵创K16：用 Vulkan 技术将语音识别放到 GPU（60s → ~3s）
- 橘宝R16：RTX 5060 原生支持 CUDA，**直接安装即可**（60s → ~1s）

**结果：**在线模式即时响应，离线模式 3-8 秒启动

# 阶段 2：用户界面 + 混合模式

---

## 计划 006b：在线/离线自动切换

- 云端不可用时自动切离线，用户无感知
- 解决中国网络环境下的可用性问题的

## 计划 007：保留猫爪 UI，替换底层引擎

- 用户看到的界面不变（猫爪按钮 + 波形动画）
- 内部传输层升级为更成熟的 QAA 协议
- 新增在线/离线切换按钮

**结果：**用户体验一致，底层更稳定

# 阶段 3+4：AI 工具调用 + 本地大模型

---

## 计划 009：AI 语音 → 工具调用

- 用户说话 → 简单问题即时回答
- 需要工具时（代码/文件/搜索）→ 后台执行 → 语音播报结果
- AI 语音成为工作入口，不仅仅是聊天

## 计划 010：本地大模型推理

- 灵创K16：35B 大模型完全驻留 96GB 显存（最高质量）
- 橘宝R16：同一 35B 模型，智能分配到 RTX 5060 + 系统内存
- **零 API 费用**，完全本地运行

**结果：**语音驱动的 AI 代理，可执行任务，零云端成本

# 两台设备最终效果对比

| 指标    | 灵创K16            | 橘宝R16            |
|-------|------------------|------------------|
| 语音启动  | 即时（在线） / ~8s（离线） | 即时（在线） / ~3s（离线） |
| 语音识别  | GPU ~3s (Vulkan) | GPU ~1s (CUDA)   |
| AI 模型 | 35B 大模型（最高质量）    | 同 35B 模型（稍压缩）    |
| 离线运行  | ✅ 零云端            | ✅ 零云端            |
| 实现难度  | 中等（需编译）          | 简单（直接安装）         |

**总结：**灵创K16 以大显存追求最高质量；橘宝R16 以 CUDA 追求最快速度和最简部署



# 成本与风险

## 开发成本：

| 项目    | 灵创K16            | 橘宝R16 |
|-------|------------------|-------|
| 云端语音  | 90天免费，后 ~¥0.20/分 | 同     |
| 离线运行  | 零成本              | 零成本   |
| 开发工作量 | 中等               | 较低    |

## 风险：

| 风险      | 级别 | 缓解措施     |
|---------|----|----------|
| 云端服务不可用 | 低  | 自动切离线模式  |
| GPU 兼容性 | 中  | 已验证两平台驱动 |
| 模型性能不足  | 低  | 可切换更小模型  |

# 项目愿景

---

**agent-meow** 是一个语音优先的 AI 代理，用户通过说话即可：

-  **对话**：自然语言交流，中英文双语
-  **执行任务**：调用代码、文件、搜索等工具
-  **完全本地**：离线可用，零云端费用
-  **品牌体验**：猫爪 UI，独特的交互设计

## 双平台覆盖：

- 灵创K16 面向高端用户（96GB 显存，最大模型）
- 橘宝R16 面向主流用户（RTX 5060 CUDA，性价比高）

两个平台运行同一软件，提供同一体验，适配不同硬件。