

agent-meow 实施范围报告

计划 001-010 · 完整实施路线图 (橘宝R16)

运行环境: 橘宝R16 · AMD Ryzen AI 9 HX 470 + RTX 5060 (8GB CUDA)

四引擎: CPU 12C + dGPU 8GB CUDA + iGPU 890M + NPU XDNA 2 · **日期:** 2026-08-04

状态: 可行性评估中 · 灵创K16 方案已推送至 `origin/main`

硬件平台 & HX470+5060 架构

组件	规格	状态
CPU	AMD Ryzen AI 9 HX 470, 12C/24T (Gorgon Point)	✓
iGPU	Radeon 890M (RDNA 3.5)	✓
iGPU 显存	32GB 统一内存	✓
dGPU	RTX 5060 Laptop (8GB GDDR7, Blackwell)	✓
dGPU 计算	CUDA + Vulkan (原生支持)	✓
NPU	AMD XDNA 2 (~50 TOPS)	✓
CUDA	RTX 5060 原生 CUDA 支持	✓
ROCm	7.1 (iGPU Vulkan 优先)	✓
内存	32GB DDR5-5600	✓

HX470+5060 独特性： RTX 5060 提供原生 CUDA → faster-whisper **直接可用**，无需 whisper.cpp Vulkan 替代。8GB GDDR7 独立显存 + 32GB 统一内存 = 混合 offload 架构。预填充 A3B 活跃层 + Whisper 到 dGPU 后，iGPU 890M + NPU 通过统一内存承担辅助计算

计划 001-005：基础设施修复

#	计划	状态	内容
001	db_models 路径	TODO	路径精确化
002	VIDEOS_SURFACE.md	TODO	过时声明
003	Phase 4 runner	TODO	注册工具
004	过时 voicebox	TODO	清理废弃
005	Voicebox 可靠性	DRAFT	被 006+008 取代

优先级： 低于 QAA 语音迁移。代码卫生修复不依赖硬件平台，与灵创K16 完全通用。

计划 006+006b: QAA 网关 + 混合部署

已解决: 原 S2S 冷启动 90 秒问题已通过 QAA 网关 + GPU STT 解决。

橘宝R16 优势: RTX 5060 有 **CUDA** → faster-whisper 直接可用，无需替代方案!

混合方案: QAA v1.3.0 网关支持在线/离线双模式切换——在线用 DashScope `qwen-audio-3.0-realtime-flash` (阿里云, OpenAI Realtime 协议, 中国可直连), 离线用本地 faster-whisper + Ollama + Kokoro。

指标	优化前	已实现
预热	90s	~0s 在线 / ~3s 离线
成本	免费	在线 90天免费, 后 ~¥0.20/分 • 离线 零

```
浏览器 → Vite(ws:true) → QAA(:3101)
├─ ☁ DashScope (~0s) ─┬─ 自动回退
└─ 🏠 本地 S2S (:8765)
    ├─ STT: faster-whisper CUDA (GPU, ~1s)
    ├─ LLM: Ollama CUDA (GPU, ~3-5s)
    └─ TTS: Kokoro (CPU, ~0s)
```

计划 007：QAA 语音钩子 → MeowCat 界面

保留猫爪 UI，替换传输层 — 与硬件无关

旧组件	新组件	动作
realtimeVoice.ts (221行)	QAA useRealtimeVoice.js	替换
s2s_proxy.py (233行)	QAA 网关	替换
猫爪按钮+波形	保留	不变

协议差异：QAA 用 `GatewayClientEvent` JSON 协议 vs 当前自定义二进制帧。需重写事件处理器，React 组件树不变。风险: MED · 工作量: L

计划 008：Qwen3-ASR + CUDA GPU STT（离线）

已选定： Qwen3-ASR-0.6B 作为离线 STT 模型（替代 faster-whisper）。

- Qwen 团队开源，支持 52 种语言，在开源 ASR 中达到 SOTA
- vLLM 部署，RTX 5060 dGPU 运行，~2.5GB 显存
- 流式/离线统一推理，0.6B 版本达到 2000 倍吞吐量（并发 128）
- **为何不用 1.7B**：8GB dGPU 需与 MoE 3B 活跃层共存，1.7B (5GB) + 3B (3GB) = 8GB 无余量；0.6B (2.5GB) + 3B (3GB) = 5.5GB，剩余 2.5GB 

组件	优化前	已实现	位置
STT	CPU 60s	GPU ~1s	dGPU
TTS	CPU 30s	~0s 预热	CPU
总预热	90s	~3s 或 0s	—

显存： Qwen3-ASR-0.6B ~2.5GB + MoE 活跃层 3B ~3GB = 5.5GB，剩余 2.5GB。风险: **LOW** • 工作量: **S**
(`pip install vllm` + 模型下载)

Qwen3 开源语音模型（已选定）

已确认模型选型——Qwen3-ASR-0.6B 替代 faster-whisper，Kokoro 保留

模型	大小	用途	R16 选用	来源
Qwen3-ASR-1.7B	~4.7GB (BF16)	STT（52 语言 SOTA）	✗ 太大(8GB dGPU)	HuggingFace
Qwen3-ASR-0.6B	~1.9GB (BF16)	STT（轻量）	✓ 已选	HuggingFace
Qwen3-TTS-0.6B	~1.9GB	TTS（轻量）	未来升级	HuggingFace
Qwen3-Omni-30B-A3B	~60GB (BF16)	全栈 S2S（端到端）	✗ 不可行(需15GB+)	HuggingFace

vLLM 集成： `vllm serve Qwen/Qwen3-ASR-0.6B` → QAA 网关指向新 STT 端点。

离线管道： QAA (:3101) → Qwen3-ASR-0.6B (dGPU) → Hermes (:8642) → Ollama (dGPU+RAM) → Kokoro (CPU)

计划 009+010： ACP 垫片 → Hermes → Ollama 本地

009： ACP 垫片解耦语音前端与 Hermes 代理 OS。简单问题即时回答；工具调用 `spawn_thinking` 后台异步执行，完成后播报。

010： Ollama + CUDA (RTX 5060) 本地 GPU 推理。

指标	Hermes Docker	Ollama 本地 (CUDA)
推理	远程 API	GPU (CUDA)
延迟	~1.8ms	~0.3ms
成本	API 费用	零

模型策略： Qwen3.6-35B-A3B (MoE, 仅 3B 激活) — 与灵创K16 同模型架构

- 活跃层 (3B) 驻留 8GB dGPU GDDR7
- 256 专家分布 dGPU + iGPU 890M + 系统 RAM (IQ3_XXS ~13GB 或 Q4_K_M ~22GB)
- iGPU 890M 通过 32GB 统一内存辅助 MoE 专家推理
- NPU XDNA 2 (~50 TOPS) 承担辅助推理/未来 STT 卸载

HX470+5060 四引擎混合 offload 优化栈

组件	引擎	位置	预热	计划
LLM (35B-A3B MoE)	Ollama+CUDA	dGPU 8GB+RAM+iGPU	~3-5s	010
STT (Qwen3-ASR-0.6B)	vLLM+CUDA	dGPU	~1s	008
TTS (Kokoro)	Kokoro-82M	CPU	~0s	008
VAD (Silero)	Silero	CPU	~0s	现有
语音网关	QAA (Node.js)	CPU	~2s	006
代理 OS	Hermes/Ollama	CPU+dGPU	已运行	009/010
MoE 专家 offload	iGPU 890M+RAM	iGPU 32GB 统一内存	已预填充	010
辅助推理	NPU XDNA 2	NPU ~50 TOPS	已就绪	010
前端	React+Vite	浏览器	即时	007

显存预算：8GB GDDR7 = MoE 活跃层 3B (~3GB) + Qwen3-ASR-0.6B (~2.5GB) = 5.5GB，剩余 2.5GB。

统一内存：32GB = MoE 专家层 (IQ3_XXS ~13GB) + 系统开销。预填充后 iGPU 890M + NPU 均活跃。

依赖关系与执行顺序

006 (QAA) → 007 (语音钩子) ← 008 (faster-whisper CUDA)
006 → 009 (ACP 垫片) → 010 (Ollama LLM CUDA)
006b (混合接线) → 007

阶段	计划	说明
1	006 + 008	并行 (008 = pip install)
2	006b + 007	依赖 006
3	009	依赖 006
4	010	依赖 009

对比灵创K16：橘宝R16 用 Qwen3-ASR-0.6B (8GB dGPU 适配)；K16 用 1.7B (96GB 充裕)。计划 010 使用同一 35B-A3B MoE 模型，但 IQ3 量化 + GPU/RAM 混合 offload。

已实现效果

指标	优化前	已实现
语音预热	90s	~0s 在线 / ~3s 离线
LLM 推理	远程 API	本地 GPU (CUDA, 8GB+RAM)
STT 推理	CPU 60s	GPU Qwen3-ASR ~1s
云端依赖	必须	可选 (混合)
成本	API 费用	在线付费 / 离线零
GPU 利用率	0%	四引擎全活跃
代理能力	无	Hermes OS

agent-meow 在橘宝R16：四引擎协同的混合部署 AI 语音代理。在线模式 QAA + DashScope 即时响应，离线模式 Qwen3-ASR-0.6B (dGPU vLLM) → Hermes (:8642) → Ollama qwen3.6:35b-a3b IQ3_XXS (dGPU+RAM CUDA) → Kokoro (CPU)。iGPU 890M 辅助 MoE 专家，NPU XDNA 2 辅助推理。预填充后所有引擎活跃，混合部署，零外部 GPU。**实现难度低于灵创K16**（CUDA 原生 vs ROCm）。

双平台部署与交付策略

目标： agent-meow 同时交付灵创K16 (395) 和橘宝R16 (HX470+5060) 两台 AIPC

维度	灵创K16 (395)	橘宝R16 (HX470+5060)
STT 模型	Qwen3-ASR-1.7B (~5GB)	Qwen3-ASR-0.6B (~2.5GB)
LLM 模型	qwen3.6:35b-a3b-q8_0 (38GB)	qwen3.6:35b-a3b IQ3_XXS (~13GB)
GPU 后端	ROCm 7.1 (HIP)	CUDA (RTX 5060)
VRAM	96GB iGPU	8GB dGPU + 32GB 统一内存
配置差异	HIP_VISIBLE_DEVICES=0	CUDA_VISIBLE_DEVICES=0

交付方案（研究阶段）：

- 统一安装包** — agent-meow 核心 + 平台检测脚本自动选择模型配置
- 平台 profile** — `profiles/k16-strix-halo.yaml` vs `profiles/r16-hx470-5060.yaml`
- 模型预下载** — 安装时按 profile 下载对应 STT/LLM 模型
- 启动脚本** — `start-voice-stack.ps1` 读取 profile 自动配置 QAA + Hermes + Ollama