

agent-meow 实施范围报告

计划 001-010 · 完整实施路线图

运行环境: 灵创K16 (COLORFIRE LinC K16) · AMD Ryzen AI MAX+ 395 (Strix Halo)

四引擎: CPU 16C + iGPU 96GB + NPU XDNA 2 + 128GB 统一内存 · **日期:** 2026-08-04

状态: 全部已推送至 `origin/main`

硬件平台 & Strix Halo 架构

组件	规格	状态
CPU	AMD Ryzen AI MAX+ 395, 16C/32T, 3.0GHz	✓
iGPU	Radeon 8060S, Vulkan 1.4.329	✓
iGPU 显存	96GB 统一内存 (128GB 总内存分配)	✓
NPU	AMD XDNA 2 (活跃辅助推理)	✓
ROCm	7.1 + HIP 7.1.51803 (活跃 GPU 后端)	✓
内存	128GB LPDDR5x-8000	✓
Ollama	0.32.5, qwen3.6:35b-a3b-q8_0 (38GB, GPU)	✓

Strix Halo 独特性：四引擎共享 128GB 统一内存池，零拷贝。iGPU 可分配 96GB 显存。**ROCm 7.1 活跃**——`HIP_VISIBLE_DEVICES=0` 激活 HIP 后端，Ollama 在 Radeon 8060S 上跑 LLM 推理。38GB 模型完全驻留 96GB 显存。NPU XDNA 2 承担辅助推理。

计划 001-005：基础设施修复

#	计划	状态	内容
001	db_models 路径	TODO	路径精确化
002	VIDEOS_SURFACE.md	TODO	过时声明
003	Phase 4 runner	TODO	注册工具
004	过时 voicebox	TODO	清理废弃
005	Voicebox 可靠性	DRAFT	被 006+008 取代

优先级：低于 QAA 语音迁移。005 原用 faster-whisper 优化，根因分析发现 CUDA-only 限制无法在 AMD GPU 绕过。

计划 006+006b: QAA 网关 + 混合部署

已解决: 原 S2S 冷启动 90 秒问题已通过 QAA 网关 + GPU STT 解决。faster-whisper 仅 CUDA 的限制由 whisper.cpp Vulkan 绕过。

混合方案: QAA v1.3.0 网关支持在线/离线双模式切换——在线用 DashScope `qwen-audio-3.0-realtime-flash` (阿里云, OpenAI Realtime 协议, 中国可直连), 离线用本地 whisper.cpp + Ollama + Kokoro。

指标	优化前	已实现
预热	90s	~0s 在线 / ~8s 离线
成本	免费	在线 90天免费, 后 ~¥0.20/分 · 离线 零

```
浏览器 → Vite(ws:true) → QAA(:3101)
├─ ☁ DashScope (~0s)    └─ 自动回退
└─ 🏠 本地 S2S (:8765)
    ├─ STT: whisper.cpp Vulkan (GPU, ~3s)
    ├─ LLM: Ollama ROCm (GPU, ~3-5s)
    └─ TTS: Kokoro (CPU, ~0s)
```

计划 007：QAA 语音钩子 → MeowCat 界面

保留猫爪 UI，替换传输层

旧组件	新组件	动作
realtimeVoice.ts (221行)	QAA useRealtimeVoice.js	替换
s2s_proxy.py (233行)	QAA 网关	替换
猫爪按钮+波形	保留	不变

协议差异：QAA 用 `GatewayClientEvent` JSON 协议 vs 当前自定义二进制帧。需重写事件处理器，React 组件树不变。风险: MED · 工作量: L

计划 008: whisper.cpp + Vulkan GPU STT (离线)

已解决: faster-whisper 仅 CUDA 的限制由 whisper.cpp v1.9.1 Vulkan 后端 (`GGML_VULKAN=1`) 绕过, STT 放到 iGPU。

Qwen3-ASR 开源替代 (研究中): Qwen3-ASR-1.7B 是 Qwen 团队发布的开源 STT 模型, 支持 52 种语言, 在开源 ASR 中达到 SOTA。可在本地 GPU 运行, 作为 whisper.cpp 的替代方案。

组件	优化前	已实现	位置
STT	CPU 60s	GPU ~3s	iGPU
TTS	CPU 30s	~0s 预热	CPU
总预热	90s	~8s 或 0s	—

显存: whisper 1.5GB + LLM 38GB = 39.5GB, 剩余 56.5GB 充裕。风险: MED • 工作量: M

Qwen3 开源语音模型（研究中）

Qwen3-ASR — 开源 STT，52 种语言，SOTA 级别

模型	大小	用途	开源	来源
Qwen3-ASR-1.7B	1.7B	STT（52 语言）	✓ 免费	HuggingFace
Qwen3-ASR-0.6B	0.6B	STT（轻量）	✓ 免费	HuggingFace
Qwen3-TTS-1.7B	1.7B	TTS（语音设计+克隆）	✓ 免费	HuggingFace
Qwen3-TTS-0.6B	0.6B	TTS（轻量）	✓ 免费	HuggingFace
Qwen3-Omni-30B-A3B	30B (3B 激活)	全栈 S2S（STT+LLM+TTS）	✓ 免费	HuggingFace

优势：Qwen3-ASR-1.7B 在开源 ASR 中达到 SOTA，支持流式/离线统一推理。Qwen3-TTS 支持语音设计和 3 秒声音克隆。Qwen3-Omni-30B-A3B 是端到端语音代理（MoE 仅 3B 激活，与现有 LLM 同架构）。

离线路径升级：whisper.cpp → Qwen3-ASR • Kokoro → Qwen3-TTS • 或直接用 Qwen3-Omni 端到端

计划 009+010: ACP 垫片 → Hermes → Ollama 本地

009: ACP 垫片解耦语音前端与 Hermes 代理 OS。简单问题即时回答；工具调用 `spawn_thinking` 后台异步执行，完成后播报。

010: 从 Hermes Docker 到 Ollama 本地 GPU 推理。

指标	Hermes Docker	Ollama 本地
推理	远程 API	GPU (ROCm)
延迟	~1.8ms	~0.3ms
成本	API 费用	零

38GB 模型在 96GB 显存占 40%，无交换。**ROCm 7.1 活跃:** `HIP_VISIBLE_DEVICES=0` 让 Ollama 使用 HIP 后端在 iGPU 上推理。Hermes = 代理 OS (skills+memory+cron+MCP)。风险: MED • 工作量: L+M

Strix Halo 四引擎优化栈

组件	引擎	位置	预热	计划
LLM (qwen3.6:35b-a3b)	Ollama+ROCM	iGPU 96GB	~3-5s	010
STT (Whisper)	whisper.cpp+Vulkan	iGPU	~3s	008
TTS (Kokoro)	Kokoro-82M	CPU	~0s	008
VAD (Silero)	Silero	CPU	~0s	现有
语音网关	QAA (Node.js)	CPU	~2s	006
代理 OS	Hermes/Ollama	CPU+iGPU	已运行	009/010
前端	React+Vite	浏览器	即时	007
辅助推理	NPU XDNA 2	NPU	已就绪	010
NPU STT (未来)	winml	NPU	待 2026 末	未来

显存预算：96GB (iGPU 分配) = LLM 38GB + STT 1.5GB = 39.5GB，剩余 56.5GB。总系统内存 128GB。

依赖关系与执行顺序

006 (QAA) → 007 (语音钩子) ← 008 (whisper.cpp)
006 → 009 (ACP 垫片) → 010 (Ollama LLM)
006b (混合接线) → 007

阶段	计划	说明
1	006 + 008	并行, 独立
2	006b + 007	依赖 006
3	009	依赖 006
4	010	依赖 009

006 和 008 可完全并行——前者 QAA 网关 + DashScope 在线，后者本地 GPU STT 加速。007 需两者都完成。

已实现效果

指标	优化前	已实现
语音预热	90s	~0s 在线 / ~8s 离线
LLM 推理	远程 API	本地 GPU (ROCm, 96GB)
STT 推理	CPU 60s	GPU Vulkan ~3s
云端依赖	必须	可选 (混合)
成本	API 费用	在线付费 / 离线零
GPU 利用率	0%	四引擎全活跃
代理能力	无	Hermes OS

agent-meow 在灵创K16：为 Strix Halo 四引擎全面优化的本地 AI 语音代理。在线模式 QAA + DashScope 即时响应，离线模式 LLM 在 iGPU（Ollama + ROCm 7.1 活跃），STT 在 iGPU（whisper.cpp + Vulkan），TTS 在 CPU，NPU XDNA 2 辅助推理，代理 OS 在后台。128GB 统一内存，零拷贝。混合部署，零外部 GPU。