

agent-meow 实施范围报告

计划 001–010 · 完整实施路线图

运行环境：Colorfire Meow Series R16 395 AI 笔记本
芯片：AMD Ryzen AI MAX+ 395 (Strix Halo) · CPU + NPU + iGPU 全栈优化

硬件平台 — Colorfire R16 395 AI

组件	规格	状态
CPU	AMD Ryzen AI MAX+ 395, 16C/32T, 3.0GHz	✓
iGPU	AMD Radeon 8060S, Vulkan 1.4.329	✓
iGPU 显存	96GB (统一内存, 驱动确认)	✓
NPU	AMD XDNA 2 (PCI 已识别)	✓
内存	32GB DDR5	✓
ROCm	7.1 + HIP 7.1.51803	✓
Ollama	0.32.5, meow36b + qwen3.6:35b-a3b (38GB)	✓
品牌	COLORFIRE LinC K16 (喵星系列)	BIOS 确认

为什么 Strix Halo 让 agent-meow 独特

普通 PC: CPU 计算 + GPU 图形 + 无 NPU
Strix Halo: CPU + iGPU(96GB) + NPU 三引擎并行, 统一内存池

Colorfire R16 · Strix Halo · iGPU 96GB 显存

CPU (16核)

├ Kokoro TTS

├ VAD Silero

├ QAA 网关

└ Vite 前端

iGPU (8060S)

├ Ollama qwen3.6 LLM (38GB)

└ whisper.cpp STT (Vulkan)

NPU (XDNA 2)

└ 未来: NPU STT (待 2026 末)

独特价值: 唯一为 Strix Halo 三引擎优化的本地 AI 语音代理。
LLM 在 GPU、STT 在 GPU、TTS 在 CPU、NPU 留给未来。零云端，零外部 GPU。

计划 001–005：基础设施修复

#	计划	状态	内容
001	修复 db_models 路径	TODO	路径精确化
002	同步 VIDEOS_SURFACE.md	TODO	2 项过时声明
003	Phase 4 runner 调度	TODO	注册工具到 runner
004	标记过时 voicebox 计划	TODO	清理废弃计划
005	Voicebox 引擎可靠性	DRAFT	预 QAA 方案

优先级低于 QAA 语音迁移。

计划 006：QAA 网关 + DashScope 云端

在线语音模式 · 解决 90 秒预热


安装 QAA 作为语音网关，配置 DashScope `qwen-audio-3.0-realtime-flash`。

指标	当前	优化后
预热	90 秒	~0 秒（云端常驻）
中文	✅	✅（原生）
成本	免费	90 天免费, 后 ~¥0.20/分
网络	无	需要互联网

步骤: DashScope 密钥 → 安装 QAA → 配置 → 冒烟测试
风险: LOW · 工作量: S

计划 006b：在线/离线混合部署接线

浏览器 → QAA → DashScope/S2S 完整连接



关键: Vite `ws: true` 启用 WebSocket 代理
自动回退: DashScope 不可用时切离线

计划 007：移植 QAA 语音钩子到 MeowCat 界面

保留猫爪 UI, 替换底层传输

旧组件	新组件	动作
realtimeVoice.ts	QAA useRealtimeVoice.js	替换
s2s_proxy.py	QAA 网关	替换
猫爪按钮+波形	保留	不变
在线/离线切换	新增	 / 

协议差异: QAA 使用 GatewayClientEvent 协议, 需重写事件处理器
风险: MED · 工作量: L

计划 008：whisper.cpp + Vulkan GPU 加速 STT

离线预热优化 · GPU 从闲置到全速

根因: faster-whisper 只支持 CUDA, AMD GPU **96GB 显存闲置**, STT 在 CPU 跑 60 秒。
方案: whisper.cpp 支持 Vulkan (`GGML_VULKAN=1`), 将 STT 放到 Radeon 8060S。

组件	当前	优化后	位置
STT	CPU 60s	GPU ~3s	iGPU
TTS	CPU 30s	~0s 预热	CPU
总预热	90s	~8s 或 0s	—

96GB iGPU 显存同时容纳 whisper + Ollama LLM。风险: MED · 工作量: M

计划 009：ACP 垫片 → Hermes 代理 OS

非阻塞工具调用语音 (Path B)

用户说话 → QAA 实时前端 → 简单问题即时回答

→ spawn_thinking → ACP 垫片 → Hermes

→ 工具调用(代码/文件/MCP) → 完成后语音播报

Hermes = 代理 OS: skills + memory + cron + terminal + MCP 集成。
ACP 垫片让语音成为 Hermes 的一等交互界面。风险: MED · 工作量: L

计划 010：本地 Ollama LLM · Strix Halo 全栈

从 Hermes Docker 到完全本地 GPU 推理

指标	Hermes Docker	Ollama 本地
内存	~1-2GB (VM)	~0 (原生)
启动	~5-10s	~3s
推理	远程 API	GPU (ROCm)
延迟	~1.8ms	~0.3ms
成本	API 费用	零

38GB 模型在 96GB iGPU 显存中: 充裕, 无交换。风险: MED · 工作量: M

完整 Strix Halo 优化栈

CPU + iGPU + NPU 三引擎分工

组件	引擎	位置	预热	计划
LLM (qwen3.6:35b)	Ollama+ROCm	iGPU 96GB	~3-5s	010
STT (Whisper)	whisper.cpp+Vulkan	iGPU	~3s	008
TTS (Kokoro)	Kokoro-82M	CPU	~0s	008
VAD (Silero)	Silero	CPU	~0s	现有
语音网关	QAA (Node.js)	CPU	~2s	006
代理 OS	Hermes/Ollama	CPU+iGPU	已运行	009/010
前端	React+Vite	浏览器	即时	007
NPU STT	未来 (winml)	NPU	待 2026 末	未来

iGPU 96GB: LLM 38GB + STT 1.5GB = 39.5GB, 剩余 56.5GB 充裕

依赖关系与执行顺序

006 (QAA+DashScope) → 007 (移植语音钩子)
006 → 009 (ACP 垫片)
008 (whisper.cpp) → 007 (并行, 独立)
009 → 010 (Ollama LLM)
006b (混合接线) → 007

阶段	计划	说明
1	006 + 008	并行, 独立
2	006b + 007	依赖 006
3	009	依赖 006
4	010	依赖 009

预期最终效果

指标	当前	最终目标
语音预热	90s	~0s 在线 / ~8s 离线
LLM 推理	远程 API	本地 GPU (ROCm, 96GB)
STT 推理	CPU 60s	GPU Vulkan ~3s
TTS 预热	30s	~0s (预热)
云端依赖	必须	可选 (混合)
成本	API 费用	零 (离线)
GPU 利用率	0%	STT + LLM 在 GPU
NPU 利用率	0%	未来 STT
Docker	必须	可选 (Ollama)
代理能力	无	Hermes OS (代码/文件/MCP)

agent-meow 在 Colorfire R16 395 AI: 唯一为 Strix Halo 三引擎 (CPU+iGPU+NPU) 全面优化的本地 AI 语音代理。LLM 在 GPU (Ollama+ROCm), STT 在 GPU (whisper.cpp+Vulkan), TTS 在 CPU (Kokoro), 代理 OS 在后台 (Hermes), NPU 留给未来。全部共享 96GB 统一显存, 零云端, 零外部 GPU。