

agent-meow 实施范围报告

计划 001-010 · 完整实施路线图

运行环境: 灵创K16 (COLORFIRE LinC K16) · AMD Ryzen AI MAX+ 395 (Strix Halo)

四引擎: CPU 16C + iGPU 96GB + NPU XDNA 2 + 128GB 统一内存 · **日期:** 2026-08-04

状态: 全部已推送至 `origin/main`

硬件平台 & Strix Halo 架构

组件	规格	状态
CPU	AMD Ryzen AI MAX+ 395, 16C/32T, 3.0GHz	✓
iGPU	Radeon 8060S, Vulkan 1.4.329	✓
iGPU 显存	96GB 统一内存 (128GB 总内存分配)	✓
NPU	AMD XDNA 2 (活跃辅助推理)	✓
ROCm	7.1 + HIP 7.1.51803 (活跃 GPU 后端)	✓
内存	128GB LPDDR5x-8000	✓
Ollama	0.32.5, qwen3.6:35b-a3b-q8_0 (38GB, GPU)	✓

Strix Halo 独特性：四引擎共享 128GB 统一内存池，零拷贝。iGPU 可分配 96GB 显存。**ROCm 7.1 活跃**——`HIP_VISIBLE_DEVICES=0` 激活 HIP 后端，Ollama 在 Radeon 8060S 上跑 LLM 推理。38GB 模型完全驻留 96GB 显存。NPU XDNA 2 承担辅助推理。

计划 001-005：基础设施修复

#	计划	状态	内容
001	db_models 路径	TODO	路径精确化
002	VIDEOS_SURFACE.md	TODO	过时声明
003	Phase 4 runner	TODO	注册工具
004	过时 voicebox	TODO	清理废弃
005	Voicebox 可靠性	DRAFT	被 006+008 取代

优先级： 低于 QAA 语音迁移。005 原用 faster-whisper 优化，根因分析发现 CUDA-only 限制无法在 AMD GPU 绕过。

计划 006+006b: QAA 网关 + 混合部署

已解决: 原 S2S 冷启动 90 秒问题已通过 QAA 网关 + GPU STT 解决。faster-whisper 仅 CUDA 的限制由 whisper.cpp Vulkan 绕过。

混合方案: QAA v1.3.0 网关支持在线/离线双模式切换——在线用 DashScope `qwen-audio-3.0-realtime-flash` (阿里云, OpenAI Realtime 协议, 中国可直连), 离线用本地 whisper.cpp + Ollama + Kokoro。

指标	优化前	已实现
预热	90s	~0s 在线 / ~8s 离线
成本	免费	在线 90天免费, 后 ~¥0.20/分 · 离线 零

```
浏览器 → Vite(ws:true) → QAA(:3101)
├─ ☁ DashScope (~0s)    └─ 自动回退
└─ 🏠 本地 S2S (:8765)
    ├─ STT: whisper.cpp Vulkan (GPU, ~3s)
    ├─ LLM: Ollama ROCm (GPU, ~3-5s)
    └─ TTS: Kokoro (CPU, ~0s)
```

计划 007：QAA 语音钩子 → MeowCat 界面

保留猫爪 UI，替换传输层

旧组件	新组件	动作
realtimeVoice.ts (221行)	QAA useRealtimeVoice.js	替换
s2s_proxy.py (233行)	QAA 网关	替换
猫爪按钮+波形	保留	不变

协议差异：QAA 用 `GatewayClientEvent` JSON 协议 vs 当前自定义二进制帧。需重写事件处理器，React 组件树不变。风险: MED · 工作量: L

计划 008：Qwen3-ASR + Vulkan GPU STT（离线）

已选定： Qwen3-ASR-1.7B 作为离线 STT 模型（替代 whisper.cpp）。

- Qwen 团队开源，支持 52 种语言，在开源 ASR 中达到 SOTA
- vLLM 部署，iGPU 运行，~5GB 显存
- 流式/离线统一推理，支持长音频转写

组件	优化前	已实现	位置
STT	CPU 60s	GPU ~3s	iGPU
TTS	CPU 30s	~0s 预热	CPU
总预热	90s	~8s 或 0s	—

显存： Qwen3-ASR-1.7B ~5GB + LLM 38GB = 43GB，剩余 53GB 充裕。风险: MED • 工作量: M

Qwen3 开源语音模型（已选定）

已确认模型选型——Qwen3-ASR 替代 whisper.cpp，Kokoro 保留（后续可升级 Qwen3-TTS）

模型	大小	用途	K16 选用	来源
Qwen3-ASR-1.7B	~4.7GB (BF16)	STT（52 语言 SOTA）	✅ 已选	HuggingFace
Qwen3-ASR-0.6B	~1.9GB (BF16)	STT（轻量）	备选	HuggingFace
Qwen3-TTS-1.7B	~4.7GB	TTS（语音设计+克隆）	未来升级	HuggingFace
Qwen3-Omni-30B-A3B	~60GB (BF16)	全栈 S2S（端到端）	可行(96GB充裕)	HuggingFace

vLLM 集成： `vllm serve Qwen/Qwen3-ASR-1.7B` → QAA 网关指向新 STT 端点，无需架构变更。

离线管道： QAA (:3101) → Qwen3-ASR-1.7B (iGPU) → Hermes (:8642) → Ollama (iGPU) → Kokoro (CPU)

计划 009+010: ACP 垫片 → Hermes → Ollama 本地

009: ACP 垫片解耦语音前端与 Hermes 代理 OS。简单问题即时回答；工具调用 `spawn_thinking` 后台异步执行，完成后播报。

010: 从 Hermes Docker 到 Ollama 本地 GPU 推理。

指标	Hermes Docker	Ollama 本地
推理	远程 API	GPU (ROCm)
延迟	~1.8ms	~0.3ms
成本	API 费用	零

38GB 模型在 96GB 显存占 40%，无交换。**ROCm 7.1 活跃:** `HIP_VISIBLE_DEVICES=0` 让 Ollama 使用 HIP 后端在 iGPU 上推理。Hermes = 代理 OS (skills+memory+cron+MCP)。风险: MED • 工作量: L+M

Strix Halo 四引擎优化栈

组件	引擎	位置	预热	计划
LLM (qwen3.6:35b-a3b)	Ollama+ROCm	iGPU 96GB	~3-5s	010
STT (Qwen3-ASR-1.7B)	vLLM+ROCm	iGPU	~3s	008
TTS (Kokoro)	Kokoro-82M	CPU	~0s	008
VAD (Silero)	Silero	CPU	~0s	现有
语音网关	QAA (Node.js)	CPU	~2s	006
代理 OS	Hermes/Ollama	CPU+iGPU	已运行	009/010
前端	React+Vite	浏览器	即时	007
辅助推理	NPU XDNA 2	NPU	已就绪	010
NPU STT (未来)	winml	NPU	待 2026 末	未来

显存预算：96GB (iGPU 分配) = LLM 38GB + Qwen3-ASR 5GB = 43GB，剩余 53GB。总系统内存 128GB。

依赖关系与执行顺序

006 (QAA) → 007 (语音钩子) ← 008 (whisper.cpp)
006 → 009 (ACP 垫片) → 010 (Ollama LLM)
006b (混合接线) → 007

阶段	计划	说明
1	006 + 008	并行, 独立
2	006b + 007	依赖 006
3	009	依赖 006
4	010	依赖 009

006 和 008 可完全并行——前者 QAA 网关 + DashScope 在线，后者本地 GPU STT 加速。007 需两者都完成。

已实现效果

指标	优化前	已实现
语音预热	90s	~0s 在线 / ~8s 离线
LLM 推理	远程 API	本地 GPU (ROCm, 96GB)
STT 推理	CPU 60s	GPU Qwen3-ASR ~3s
云端依赖	必须	可选 (混合)
成本	API 费用	在线付费 / 离线零
GPU 利用率	0%	四引擎全活跃
代理能力	无	Hermes OS

agent-meow 在灵创K16：为 Strix Halo 四引擎全面优化的混合部署 AI 语音代理。在线模式 QAA + DashScope 即时响应，离线模式 Qwen3-ASR-1.7B (iGPU vLLM) → Hermes (:8642) → Ollama qwen3.6:35b-a3b-q8_0 (iGPU ROCm) → Kokoro (CPU)。NPU XDNA 2 辅助推理。128GB 统一内存，零拷贝。零外部 GPU。

双平台部署与交付策略

目标： agent-meow 同时交付灵创K16 (395) 和橘宝R16 (HX470+5060) 两台 AIPC

维度	灵创K16 (395)	橘宝R16 (HX470+5060)
STT 模型	Qwen3-ASR-1.7B (~5GB)	Qwen3-ASR-0.6B (~2.5GB)
LLM 模型	qwen3.6:35b-a3b-q8_0 (38GB)	qwen3.6:35b-a3b IQ3_XXS (~13GB)
GPU 后端	ROCm 7.1 (HIP)	CUDA (RTX 5060)
VRAM	96GB iGPU	8GB dGPU + 32GB 统一内存
配置差异	HIP_VISIBLE_DEVICES=0	CUDA_VISIBLE_DEVICES=0

交付方案（研究阶段）：

- 统一安装包** — agent-meow 核心 + 平台检测脚本自动选择模型配置
- 平台 profile** — `profiles/k16-strix-halo.yaml` vs `profiles/r16-hx470-5060.yaml`
- 模型预下载** — 安装时按 profile 下载对应 STT/LLM 模型
- 启动脚本** — `start-voice-stack.ps1` 读取 profile 自动配置 QAA + Hermes + Ollama