

agent-meow 实施范围报告

计划 001-010 · 完整实施路线图

运行环境: Colorfire R16 395 AI · AMD Ryzen AI MAX+ 395 (Strix Halo)

三引擎: CPU 16C + iGPU 96GB + NPU XDNA 2 · **日期:** 2026-08-04

状态: 全部已推送至 `origin/main`

硬件平台 & Strix Halo 架构

组件	规格	状态
CPU	AMD Ryzen AI MAX+ 395, 16C/32T	✓
iGPU	Radeon 8060S, Vulkan 1.4.329	✓
iGPU 显存	96GB 统一内存 (qwMemorySize=103GB)	✓
NPU	AMD XDNA 2	✓
ROCm	7.1 + HIP 7.1.51803 (活跃 GPU 后端)	✓
Ollama	0.32.5, qwen3.6:35b (38GB, GPU 推理)	✓

Strix Halo 独特性：三引擎共享统一内存池，零拷贝。**ROCm 7.1 活跃**——HIP_VISIBLE_DEVICES=0 激活 HIP 后端，Ollama 在 Radeon 8060S 上跑 LLM 推理。38GB 模型完全驻留 96GB 显存。

CPU：TTS+VAD+QAA网关 iGPU：LLM(38GB)+STT NPU：未来STT

计划 001-005：基础设施修复

#	计划	状态	内容
001	db_models 路径	TODO	路径精确化
002	VIDEOS_SURFACE.md	TODO	过时声明
003	Phase 4 runner	TODO	注册工具
004	过时 voicebox	TODO	清理废弃
005	Voicebox 可靠性	DRAFT	被 006+008 取代

优先级：低于 QAA 语音迁移。005 原用 faster-whisper 优化，根因分析发现 CUDA-only 限制无法在 AMD GPU 绕过。

计划 006+006b: QAA 网关 + 混合部署

痛点: S2S 冷启动 90 秒。faster-whisper 仅支持 CUDA, 96GB GPU 闲置, STT 在 CPU 跑 60 秒。

方案: QAA v1.3.0 网关 + DashScope `qwen-audio-3.0-realtime-flash` (阿里云, OpenAI Realtime 协议, 中国可直连)。

指标	当前	优化后
预热	90s	~0s 云端
成本	免费	90天免费, 后 ~¥0.20/分

```
浏览器 → Vite(ws:true) → QAA(:3101)
├─ ☁ DashScope (~0s)    └─ 自动回退
└─ 🏠 本地 S2S (:8765)
```

风险: LOW • 工作量: S • 每会话 provider 切换是架构级能力

计划 007：QAA 语音钩子 → MeowCat 界面

保留猫爪 UI，替换传输层

旧组件	新组件	动作
realtimeVoice.ts (221行)	QAA useRealtimeVoice.js	替换
s2s_proxy.py (233行)	QAA 网关	替换
猫爪按钮+波形	保留	不变

协议差异：QAA 用 `GatewayClientEvent` JSON 协议 vs 当前自定义二进制帧。需重写事件处理器，React 组件树不变。风险: MED · 工作量: L

计划 008: whisper.cpp + Vulkan GPU STT

根因: faster-whisper 仅 CUDA → 96GB GPU 闲置 → STT 在 CPU 60 秒。

方案: whisper.cpp v1.9.1 Vulkan 后端 (`GGML_VULKAN=1`), STT 放到 iGPU。

组件	当前	优化后	位置
STT	CPU 60s	GPU ~3s	iGPU
TTS	CPU 30s	~0s 预热	CPU
总预热	90s	~8s 或 0s	—

显存: whisper 1.5GB + LLM 38GB = 39.5GB, 剩余 56.5GB 充裕。风险: MED • 工作量: M

计划 009+010: ACP 垫片 → Hermes → Ollama 本地

009: ACP 垫片解耦语音前端与 Hermes 代理 OS。简单问题即时回答；工具调用 `spawn_thinking` 后台异步执行，完成后播报。

010: 从 Hermes Docker 到 Ollama 本地 GPU 推理。

指标	Hermes Docker	Ollama 本地
推理	远程 API	GPU (ROCm)
延迟	~1.8ms	~0.3ms
成本	API 费用	零

38GB 模型在 96GB 显存占 40%，无交换。**ROCm 7.1 活跃:** `HIP_VISIBLE_DEVICES=0` 让 Ollama 使用 HIP 后端在 iGPU 上推理。Hermes = 代理 OS (skills+memory+cron+MCP)。风险: MED • 工作量: L+M

Strix Halo 三引擎优化栈

组件	引擎	位置	预热	计划
LLM (qwen3.6:35b)	Ollama+ROCm	iGPU 96GB	~3-5s	010
STT (Whisper)	whisper.cpp+Vulkan	iGPU	~3s	008
TTS (Kokoro)	Kokoro-82M	CPU	~0s	008
VAD (Silero)	Silero	CPU	~0s	现有
语音网关	QAA (Node.js)	CPU	~2s	006
代理 OS	Hermes/Ollama	CPU+iGPU	已运行	009/010
前端	React+Vite	浏览器	即时	007
NPU STT	未来 (winml)	NPU	待 2026 末	未来

显存预算：96GB = LLM 38GB + STT 1.5GB = 39.5GB， 剩余 56.5GB。

依赖关系与执行顺序

006 (QAA) → 007 (语音钩子) ← 008 (whisper.cpp)
006 → 009 (ACP 垫片) → 010 (Ollama LLM)
006b (混合接线) → 007

阶段	计划	说明
1	006 + 008	并行, 独立
2	006b + 007	依赖 006
3	009	依赖 006
4	010	依赖 009

006 和 008 可完全并行——前者云端网关，后者本地 GPU STT。007 需两者都完成。

预期最终效果

指标	当前	最终目标
语音预热	90s	~0s 在线 / ~8s 离线
LLM 推理	远程 API	本地 GPU (ROCm, 96GB)
STT 推理	CPU 60s	GPU Vulkan ~3s
云端依赖	必须	可选 (混合)
成本	API 费用	零 (离线)
GPU 利用率	0%	STT + LLM 在 GPU
代理能力	无	Hermes OS

agent-meow 在 Colorfire R16：唯一为 Strix Halo 三引擎全面优化的本地 AI 语音代理。LLM 在 GPU (Ollama + ROCm 7.1 活跃)，STT 在 GPU (whisper.cpp + Vulkan)，TTS 在 CPU，代理 OS 在后台，NPU 留给未来。零云端，零外部 GPU。