

# agent-meow 实施范围报告

计划 001-010 · 完整实施路线图

**运行环境:** Colorfire R16 395 AI · AMD Ryzen AI MAX+ 395 (Strix Halo)

**三引擎:** CPU 16C + iGPU 96GB + NPU XDNA 2 · **日期:** 2026-08-04

**状态:** 全部已推送至 `origin/main`

# 硬件平台 & Strix Halo 架构

| 组件      | 规格                                 | 状态 |
|---------|------------------------------------|----|
| CPU     | AMD Ryzen AI MAX+ 395, 16C/32T     | ✓  |
| iGPU    | Radeon 8060S, Vulkan 1.4.329       | ✓  |
| iGPU 显存 | 96GB 统一内存 (qwMemorySize=103GB)     | ✓  |
| NPU     | AMD XDNA 2                         | ✓  |
| ROCm    | 7.1 + HIP 7.1.51803 (活跃 GPU 后端)    | ✓  |
| Ollama  | 0.32.5, qwen3.6:35b (38GB, GPU 推理) | ✓  |

**Strix Halo 独特性：**三引擎共享统一内存池，零拷贝。**ROCm 7.1 活跃**——HIP\_VISIBLE\_DEVICES=0 激活 HIP 后端，Ollama 在 Radeon 8060S 上跑 LLM 推理。38GB 模型完全驻留 96GB 显存。

CPU：TTS+VAD+QAA网关      iGPU：LLM(38GB)+STT      NPU：未来STT

# 计划 001-005：基础设施修复

| #   | 计划                | 状态    | 内容           |
|-----|-------------------|-------|--------------|
| 001 | db_models 路径      | TODO  | 路径精确化        |
| 002 | VIDEOS_SURFACE.md | TODO  | 过时声明         |
| 003 | Phase 4 runner    | TODO  | 注册工具         |
| 004 | 过时 voicebox       | TODO  | 清理废弃         |
| 005 | Voicebox 可靠性      | DRAFT | 被 006+008 取代 |

**优先级：**低于 QAA 语音迁移。005 原用 faster-whisper 优化，根因分析发现 CUDA-only 限制无法在 AMD GPU 绕过。

# 计划 006+006b: QAA 网关 + 混合部署

**已解决:** 原 S2S 冷启动 90 秒问题已通过 QAA 网关 + GPU STT 解决。faster-whisper 仅 CUDA 的限制由 whisper.cpp Vulkan 绕过。

**方案:** QAA v1.3.0 网关 + DashScope `qwen-audio-3.0-realtime-flash` (阿里云, OpenAI Realtime 协议, 中国可直连)。

| 指标 | 优化前 | 已实现               |
|----|-----|-------------------|
| 预热 | 90s | ~0s 云端            |
| 成本 | 免费  | 90天免费, 后 ~¥0.20/分 |

```
浏览器 → Vite(ws:true) → QAA(:3101)
├─ ☁ DashScope (~0s)    └─ 自动回退
└─ 🏠 本地 S2S (:8765)
```

风险: LOW · 工作量: S · 每会话 provider 切换是架构级能力

# 计划 007：QAA 语音钩子 → MeowCat 界面

## 保留猫爪 UI，替换传输层

| 旧组件                     | 新组件                     | 动作 |
|-------------------------|-------------------------|----|
| realtimeVoice.ts (221行) | QAA useRealtimeVoice.js | 替换 |
| s2s_proxy.py (233行)     | QAA 网关                  | 替换 |
| 猫爪按钮+波形                 | 保留                      | 不变 |

**协议差异：**QAA 用 `GatewayClientEvent` JSON 协议 vs 当前自定义二进制帧。需重写事件处理器，React 组件树不变。风险: MED · 工作量: L

# 计划 008: whisper.cpp + Vulkan GPU STT

**已解决:** faster-whisper 仅 CUDA 的限制由 whisper.cpp v1.9.1 Vulkan 后端 ( `GGML_VULKAN=1` ) 绕过, STT 放到 iGPU。

| 组件  | 优化前        | 已实现             | 位置   |
|-----|------------|-----------------|------|
| STT | CPU 60s    | <b>GPU ~3s</b>  | iGPU |
| TTS | CPU 30s    | <b>~0s</b> 预热   | CPU  |
| 总预热 | <b>90s</b> | <b>~8s</b> 或 0s | —    |

**显存:** whisper 1.5GB + LLM 38GB = 39.5GB, 剩余 56.5GB 充裕。风险: MED • 工作量: M

# 计划 009+010: ACP 垫片 → Hermes → Ollama 本地

**009:** ACP 垫片解耦语音前端与 Hermes 代理 OS。简单问题即时回答；工具调用 `spawn_thinking` 后台异步执行，完成后播报。

**010:** 从 Hermes Docker 到 Ollama 本地 GPU 推理。

| 指标 | Hermes Docker | Ollama 本地  |
|----|---------------|------------|
| 推理 | 远程 API        | GPU (ROCm) |
| 延迟 | ~1.8ms        | ~0.3ms     |
| 成本 | API 费用        | 零          |

38GB 模型在 96GB 显存占 40%，无交换。**ROCm 7.1 活跃:** `HIP_VISIBLE_DEVICES=0` 让 Ollama 使用 HIP 后端在 iGPU 上推理。Hermes = 代理 OS (skills+memory+cron+MCP)。风险: MED • 工作量: L+M

# Strix Halo 三引擎优化栈

| 组件                | 引擎                 | 位置        | 预热       | 计划      |
|-------------------|--------------------|-----------|----------|---------|
| LLM (qwen3.6:35b) | Ollama+ROCm        | iGPU 96GB | ~3-5s    | 010     |
| STT (Whisper)     | whisper.cpp+Vulkan | iGPU      | ~3s      | 008     |
| TTS (Kokoro)      | Kokoro-82M         | CPU       | ~0s      | 008     |
| VAD (Silero)      | Silero             | CPU       | ~0s      | 现有      |
| 语音网关              | QAA (Node.js)      | CPU       | ~2s      | 006     |
| 代理 OS             | Hermes/Ollama      | CPU+iGPU  | 已运行      | 009/010 |
| 前端                | React+Vite         | 浏览器       | 即时       | 007     |
| NPU STT           | 未来 (winml)         | NPU       | 待 2026 末 | 未来      |

**显存预算：**96GB = LLM 38GB + STT 1.5GB = 39.5GB， 剩余 56.5GB。

# 依赖关系与执行顺序

006 (QAA) → 007 (语音钩子) ← 008 (whisper.cpp)  
006 → 009 (ACP 垫片) → 010 (Ollama LLM)  
006b (混合接线) → 007

| 阶段 | 计划         | 说明     |
|----|------------|--------|
| 1  | 006 + 008  | 并行, 独立 |
| 2  | 006b + 007 | 依赖 006 |
| 3  | 009        | 依赖 006 |
| 4  | 010        | 依赖 009 |

006 和 008 可完全并行——前者云端网关，后者本地 GPU STT。007 需两者都完成。

# 已实现效果

| 指标      | 优化前     | 已实现                 |
|---------|---------|---------------------|
| 语音预热    | 90s     | ~0s 在线 / ~8s 离线     |
| LLM 推理  | 远程 API  | 本地 GPU (ROCm, 96GB) |
| STT 推理  | CPU 60s | GPU Vulkan ~3s      |
| 云端依赖    | 必须      | 可选 (混合)             |
| 成本      | API 费用  | 零 (离线)              |
| GPU 利用率 | 0%      | STT + LLM 在 GPU     |
| 代理能力    | 无       | Hermes OS           |

**agent-meow 在 Colorfire R16**：唯一为 Strix Halo 三引擎全面优化的本地 AI 语音代理。LLM 在 GPU (Ollama + ROCm 7.1 活跃)，STT 在 GPU (whisper.cpp + Vulkan)，TTS 在 CPU，代理 OS 在后台，NPU 留给未来。零云端，零外部 GPU。